



Suparnički napadi na modele za klasifikaciju slika

Tonka Šegvić

Prezentacija za obranu završnog rada 4.7.2025.

SUPARNIČKI NAPADI

- Cilj rada bio je pokazati kako dodavanje male perturbacije na ulaz može drastično utjecati na točnost klasifikacijskih modela

$$x' = x + \delta$$

- Različiti napadi imaju različite strategije za odabir perturbacije

Implementacija

- Napad FGSM
 - Neciljani
 - Ciljani
- Primjena na:
 - Potpuno povezani model
 - Provedeno treniranje algoritmom sgd na skupu podataka MNIST
 - Resnet-20
 - Preuzet s već optimiranim parametrima za klasifikaciju skupa CIFAR-100

FGSM (Fast Gradient Sign Method)

- Ideja
 - Pomoću predznaka gradijenta funkcije gubitka odrediti ograničenu perturbaciju tako da dodavanje te perturbacije na ulaz modela maksimizira funkciju gubitka
- White-box napad

FGSM (Fast Gradient Sign Method)

$$\mathcal{L}(\theta, x + \delta, y) \approx \mathcal{L}(\theta, x, y) + \delta^T \nabla_x \mathcal{L}(\theta, x, y)$$

$$\|\delta\|_{\infty} \leq \epsilon$$

$$\delta = \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(\theta, x, y))$$

$$x_{\text{adv}} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(\theta, x, y))$$

- θ – skup parametara modela
- x – izvorni ulaz
- y – pripadajuća oznaka (labela)
- δ – mala promjena (perturbacija) nad ulazom
- $\mathcal{L}(\theta, x + \delta, y)$ – funkcija gubitka za perturbirani ulaz
- $\mathcal{L}(\theta, x, y)$ – funkcija gubitka za neperturbirani (izvorni) ulaz
- $\nabla_x \mathcal{L}(\theta, x, y)$ – gradijent funkcije gubitka po ulazu
- ϵ – mjera veličine perturbacije

Ciljani napad

$$x_{\text{adv}} = x - \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(\theta, x, y_{\text{target}}))$$



Generiranje suparničkih primjera

- Dodavanje perturbacije na slike iz ispitnog skupa
- Samo ako se slika inicijalno točno klasificira
- Mjerimo koliki je postotak pogrešnih klasifikacija (neciljani napad), odnosno koliki je postotak klasifikacija u ciljnu klasu (ciljani napad)



Potpuno povezani model za klasifikaciju skupa MNIST

- $784 \times 512 \times 64 \times 10$
- ReLu, LogSoftmax
- sgd, 10 epoha
- NLL
- 70 000 jednokanalnih slika 28x28
- 10 klasa (znamenke)

Točnost i gubitak





MNIST, neciljani napad



MNIST, ciljani napad


- Ciljna klasa za klasu t je klasa $t+1$



Resnet-20 za klasifikaciju skupa CIFAR-100

- Preuzet s optimiziranim parametrima
- točnost 68.83% na CIFAR-100 ispitnom skupu
- Konvolucijska arhitektura, 20 slojeva, rezidualne veze
- 60 000 trokanalnih slika (RGB) 32x32
- 100 klasa podijeljenih u 20 nadklasa

CIFAR-100 Neciljani napad



Original: forest (0.78)



Adversarial: rabbit (0.41)



Perturbation ($\epsilon=0.0500$)



Original: seal (0.57)



Adversarial: otter (0.91)



Perturbation ($\epsilon=0.0500$)



Original: mushroom (0.91)



Adversarial: trout (0.97)





Perturbation ($\epsilon=0.0500$)





CIFAR-100, Ciljani napad

- Hijerarhijska struktura
- Napad kada je ciljna klasa u istoj nadklasi kao inicijalna klasa
- Napad kada ciljna klasa nije u istoj nadklasi kao inicijalna klasa

Ciljna klasa u istoj nadklasi



Ciljna klasa u različitoj nadklasi



Robusnost

- Lakše je napraviti uspješan neciljani napad na modelu Resnet-20
- Uspješnost ciljanog napada je veća za potpuno povezani model

Zaključak i budući rad

- Rad pokazuje ranjivosti modela koji postižu dobre rezultate na ispitnim skupovima na suparničke primjere
- Budući rad bi mogao uključivati:
 - Suparničko treniranje
 - Implementacija novih napada
 - Primjena FGSM-a na nove modele



Hvala na pozornosti!